Sprawozdanie Obliczenia Naukowe - Lista 1

Paweł Smolnicki

Zadanie 1

Zadanie polegało na zbadaniu właściwości typów zmiennopozycyjnych zgodnie ze standardem IEEE 754

Epsilon maszynowy

Poniżej przedstawiono porównanie wartości *macheps* wyznaczonych iteracyjnie, wartości wyznaczanych przez `eps(T)` w Julii oraz wartości zdefiniowanych w pliku nagłówkowym `float.h` języka C.

Tabela 1: Porównanie wartości macheps.

Typ	**Wartość z `float.h`**	**Wartość z `eps(T)`**	**Wyznaczona wartość**
`Float16`	—	`0.000977`	`0.000977`
`Float32`	`1.19209289e-07`	`1.1920929e-7`	`1.1920929e-7`
`Float64`	`2.22044604e-16`	`2.220446049250313e-16`	`2.220446049250313e-16`

Wartości uzyskane iteracyjnie pokrywają się z wartościami uzyskanymi przez wywołania `eps(T)`. Związek między *macheps* a precyzją arytmetyki ϵ wyraża się zależnością: macheps $= 2 \cdot \epsilon$.

Najmniejsza dodatnia liczba maszynowa

Liczba *eta* (x) to najmniejsza dodatnia wartość, jaką można reprezentować w danym standardzie zmiennoprzecinkowym. Liczba ta jest równa MIN_{sub}. Funkcja `floatmin(T)` zwraca MIN_{nor}.

Tabela 2: Porównanie wartości *eta* (x) oraz MIN_{nor}.

Typ danych	**Iteracyjna *eta***	`nextfloat(T(0.0))`	`floatmin(T)`
`Float16`	`6.0e-8`	`6.0e-8`	`6.104e-5`
`Float32`	`1.0e-45`	`1.0e-45`	`1.1754944e-38`
`Float64`	`5.0e-324`	`5.0e-324`	`2.2250738585072014e-308`

0.1 Największa wartość skończona

Liczba MAX to największa skończona wartość w danym typie zmiennoprzecinkowym.

Tabela 3: Porównanie maksymalnych wartości zmiennoprzecinkowych.

Typ	**Wartość z `float.h` (C)**	**Wartość iteracyjna**	**`floatmax(T)` (Julia)**
`Float16`	—	`6.55e4`	`6.55e4`
`Float32`	`3.40282346e+38`	`3.4028235e38`	`3.4028235e38`
`Float64`	`1.79769313e+308`	`1.7976931348623157e308`	`1.7976931348623157e308`

Zadanie 2

Celem tego zadania było sprawdzenie, jak rozmieszczone są liczby zmiennoprzecinkowe w różnych przedziałach w arytmetyce `Float64`.

Liczby zmiennoprzecinkowe w arytmetyce `Float64` są równomiernie rozłożone w podanych przedziałach. Eksperymentalnie wyznaczono krok δ dla wybranych przedziałów:

- **Przedział** $[0.5, 1)$**:** Liczby są rozmieszczone z krokiem $\delta = 2^{-53} \approx 1.1102 \cdot 10^{-16}$. Liczby mają postać $x = 0.5 + k \cdot 2^{-53},\ k = 0, 1, 2, ..., 2^{53} - 1$
- **Przedział** $[1, 2)$**:** Liczby są rozmieszczone z krokiem $\delta = 2^{-52} \approx 2.2204 \cdot 10^{-16}$. Liczby mają postać $x = 1 + k \cdot 2^{-52},\ k = 0, 1, 2, ..., 2^{52} - 1$.
- **Przedział** $[2, 4)$**:** Liczby są rozmieszczone z krokiem $\delta = 2^{-51} \approx 4.4408 \cdot 10^{-16}$. Liczby mają postać $x = 2 + k \cdot 2^{-51},\ k = 0, 1, 2, ..., 2^{51} - 1$.

Zjawisko wynika ze sposobu reprezentacji liczb w IEEE 754

Zadanie 3

Celem zadania było wyznaczenie eksperymentalnie liczby x w arytmetyce `Float64` takiej, że: $1 < x < 2$ oraz $fl(x \cdot fl(1/x)) \neq 1$.

- Liczba znaleziona eksperymentalnie:
  `1.6020374047609054`
- Najmniejsza znaleziona liczba z przedziału $(1, 2)$:
  `1.000000057228997`

Zadanie 4

Celem zadania było obliczenie iloczynu skalarnego dwóch wektorów x i y $(n = 5)$ czterema różnymi metodami. Dokładna wartość wyrażenia wynosi w przybliżeniu `-1.00657107000000e-11`.

Tabela 4: Porównanie wyników iloczynu skalarnego na podstawie metody dla typu Float64

Metoda	**Wynik (`Float64`)**	**Błąd względny w %**
(a) w przód	`1.0251881368296672e-10`	≈ 1118.5
(b) w tył	`-1.5643308870494366e-10`	≈ 1454.1
(c) od największego do najmniejszego	`0.0`	`100.0`
(d) od najmniejszego do największego	`0.0`	`100.0`

Tabela 5: Porównanie wyników iloczynu skalarnego na podstawie metody dla typu Float32

Metoda	**Wynik** (`Float32`)	**Błąd względny w %**
(a) w przód	`-0.4999443`	`4.966806e12`
(b) w tył	`-0.4543457`	`4.5137967e12`
(c) od największego do najmniejszego	`-0.5`	`4.9673593e12`
(d) od najmniejszego do największego	`-0.5`	`4.9673593e12`

Wnioski: Wyniki w arytmetyce `Float32` są niedokładne w porównaniu do prawdziwej wartości ze względu na redukcję cyfr znaczących. Kolejność dodawania ma znaczenie w arytmetyce zmiennopozycyjnej.

Zadanie 5

W zadaniu należało wyznaczyć wartości dwóch funkcji f i g, które są równoważne matematycznie, dla malejących wartości x:

$$f(x) = \sqrt{x^2+1} - 1,$$
$$g(x) = \frac{x^2}{\sqrt{x^2+1}+1}.$$

Tabela 6: Porównanie wyników ewaluacji funkcji $f(x)$ i $g(x)$.

Wartość x	$f(x)$	$g(x)$
8^{-1}	`0.0077822185373186414`	`0.0077822185373187065`
8^{-4}	`2.9802321943606103e-8`	`2.9802321943606116e-8`
8^{-7}	`1.1368683772161603e-13`	`1.1368683772160957e-13`
8^{-8}	`1.7763568394002505e-15`	`1.7763568394002489e-15`
8^{-9}	`0.0`	`2.7755575615628914e-17`
8^{-10}	`0.0`	`4.336808689942018e-19`
8^{-20}	`0.0`	`3.76158192263132e-37`
8^{-178}	`0.0`	`1.6e-322`

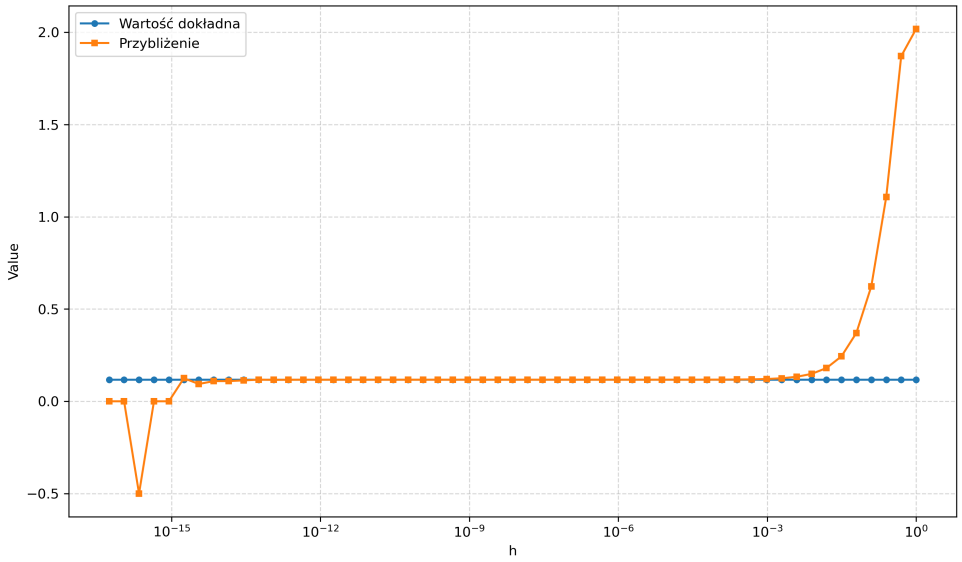
Wnioski: Pomimo, że $f \equiv g$, funkcja f zaczyna zwracać dokładnie `0.0` dla wartości x poniżej 8^{-8}. Znacznie bardziej wiarygodne są wyniki zwracane przez funkcję g. Dzieje się tak, ponieważ dla małych x, wyrażenie $\sqrt{x^2+1} \approx 1$. Odejmowanie 1 prowadzi wtedy do redukcji cyfr znaczących, przez co znacząco tracimy precyzję wyniku

Zadanie 6

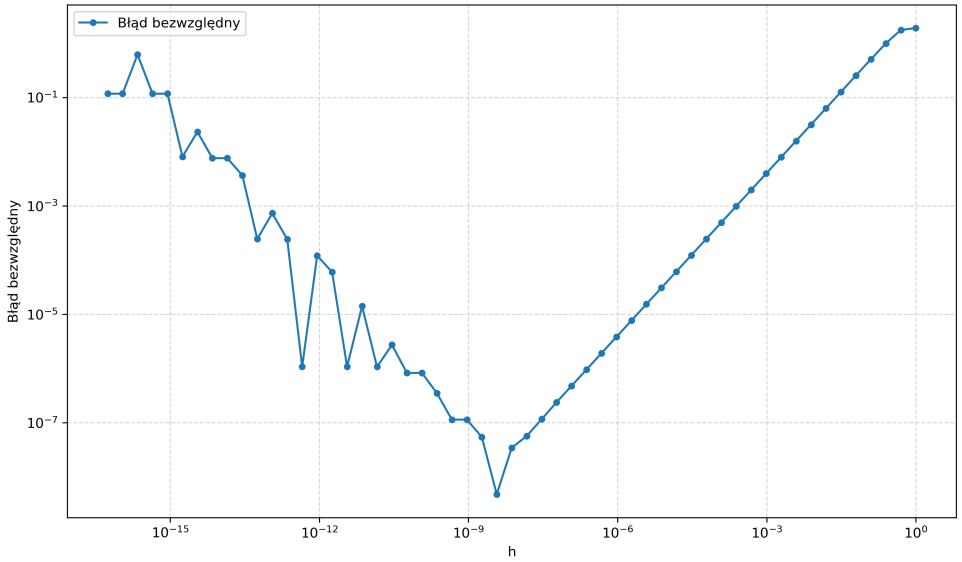
Wyznaczenie numeryczne pochodnej funkcji $f(x) = \sin(x) + \cos(3x)$ w punkcie $x_0 = 1$ ze wzoru przybliżonego:

$$\tilde{f}'(x_0) = \frac{f(x_0+h) - f(x_0)}{h}$$

oraz zbadanie błędu bezwzględnego. Dokładna wartość:
$f'(x) = \cos(x) - 3\sin(3x) \approx 0.11694228168853815$.



Rysunek 1: Wykres wartości przybliżonej od wartości parametru h.



Rysunek 2: Wykres zależności błędu bezwzględnego od wartości parametru h.

Tabela 7: Wybrane przybliżone wartości pochodnej i błędy bezwzględne.

h	$\tilde{f}'(x_0)$	$\lvert f'(x_0) - \tilde{f}'(x_0)\rvert$
2^{0}	2.0179892252685967	1.9010469435800585
2^{-10}	0.12088247681106168	0.0039401951225235265
2^{-27}	0.11694231629371643	3.460517827846843e-8
2^{-28}	0.11694228649139404	4.802855890773117e-9
2^{-29}	0.11694222688674927	5.480178888461751e-8
2^{-49}	0.125	0.008057718311461848
2^{-50}	0.0	0.11694228168853815
2^{-54}	0.0	0.11694228168853815

Wnioski: Początkowo, wraz ze zmniejszaniem wartości h, błąd przybliżenia maleje. Spośród wszystkich wartości h najmniejszy błąd otrzymujemy dla $h = 2^{-28}$. Poniżej tej wartości, pomimo że matematycznie przybliżenie staje się lepsze, błąd obliczeniowy drastycznie rośnie. Jest to spowodowane utratą precyzji w odejmowaniu, gdyż odejmujemy od siebie bardzo bliskie wartości $f(x_0 + h)$ i $f(x_0)$, co skutkuje redukcją cyfr znaczących.